

**LAPORAN TUGAS CRAWLING DAN PREPROCESSING  
DATA TEXT  
MATA KULIAH TEXT MINING & NATURAL LANGUAGE  
PROCESSING**



**Tim Penyusun:**

1. <5231811022> <Lathif Ramadhan>
2. <5231811029> <Andini Angel Meivita>
3. <5231811033> <Rama Panji Nararendra>
4. <5231811036> <Giffari Riyanda Pradithya>

**PROGRAM STUDI SAINS DATA PROGRAM SARJANA  
FAKULTAS SAINS & TEKNOLOGI  
UNIVERSITAS TEKNOLOGI YOGYAKARTA  
2025**

1. **Hastag yang digunakan:** #ramadhan

2. **Tuliskan langkah-langkah crawling data text:**

a. **Tuliskan/screenshotkan codingnya**

**Jawab:**

**Link file kodenya:**

[https://colab.research.google.com/drive/1wxDKwRGiu\\_pd9CDx6kNHN6I8RfUdxLrS#scrollTo=o2wMKSTWhoNW](https://colab.research.google.com/drive/1wxDKwRGiu_pd9CDx6kNHN6I8RfUdxLrS#scrollTo=o2wMKSTWhoNW)

```
# instal Node.js dan npm (Node Package Manager) di sistem
!curl -sL https://deb.nodesource.com/setup_18.x | sudo -E
bash -
!sudo apt-get install -y nodejs

# nama file dari data yang berhasil dikumpulkan
data = "ramadan_1.csv"

# kata kunci dari data yang ingin dicari
search_keyword = "Ramadan"

# limit baris pencarian
limit = 200

# jalankan proses crawling tweet dengan bantuan tweet-harvest
menggunakan Twitter API token.
!npx --yes tweet-harvest@2.6.1 -o "ramadan_1.csv" -s
"{Ramadan}" -l {100} --token "-----"
```

b. **Tuliskan/screenshotkan hasil crawlingnya**

**Jawab:**



```

li = []
# print(all_files)
for filename in onlyfiles:
    df = pd.read_csv( r'/content/' + filename,
index_col=None, header=0)
    li.append(df)

frame = pd.concat(li, axis=0, ignore_index=True)

frame.to_csv("fix_combined_ramadan_real.csv", index=False)

df = pd.read_csv('/content/fix_combined_ramadan_real.csv')
df

df.drop_duplicates()
df.to_csv("/content/fix_combined_ramadan.csv", index=False)

```

### Cleaning di preprocessing:

```

df.drop_duplicates(subset = 'Tweet', keep = 'first', inplace
= True)

# Memfilter datanya cuma bahasanya yang English
filt = (df_twit['lang'] == 'en')
df_twit = df_twit.loc[filt, :]
df_twit.reset_index(inplace=True)

#menghilangkan mention/user
def remove_pattern (tweet, pattern):
    r = re.findall(pattern, tweet)
    for i in r:
        tweet = re.sub(i, '', tweet)
    return tweet

df['remove_user'] = np.vectorize(remove_pattern)(df['teks'],
"@[\w]*")
df['remove_user']

```

**b. Tuliskan/screenshotkan Case folding**

**Jawab:**

Case folding adalah proses mengubah semua teks menjadi huruf kecil agar lebih konsisten dalam analisis.

→ Di kode ini, case folding terjadi secara otomatis saat tokenizing

```
#tokenize tweets
tokenizer = TweetTokenizer(preserve_case=True,
strip_handles=True, reduce_len=True)

tweet_tokens = tokenizer.tokenize(tweet)
# print(f"Word after tokenizer : {tweet_tokens}")
tweets_clean = []

for word in tweet_tokens:
    if (word not in stopwords_english and word not in
emoticons and word not in string.punctuation): # remove
punctuation
        # print(f"Word before stemming: {word}")
        stem_word = stemmer.stem(word) #stemming word
        # print(f"Word after stem: {stem_word}")
        tweets_clean.append(stem_word)
return tweets_clean
```

Parameter `preserve_case=False` dalam `TweetTokenizer` akan secara otomatis mengubah teks menjadi huruf kecil.

Kedua kode ini walaupun fungsinya untuk tokenizing dan stemming tetapi secara tidak langsung mereka juga melakukan case folding, dimana untuk tokenizer `preserve_case` nya di set ke `False` untuk di case folding.

Untuk bagian kode yang melakukan case folding di tokenizing adalah

```
tokenizer = TweetTokenizer(preserve_case=True,
strip_handles=True, reduce_len=True)
```

```
tweet_tokens = tokenizer.tokenize(tweet)
```

Dan untuk bagian kode yang melakukan case folding di stemming adalah

```
stem_word = stemmer.stem(word)
```

### c. Tuliskan/screenshotkan Tokenizing

Tokenizing adalah proses memecah teks menjadi kata-kata atau token.

**Jawab:**

→ **Bagian kode yang melakukan tokenizing:**

```
tokenizer = TweetTokenizer(preserve_case=False,
strip_handles=True, reduce_len=True)
tweet_tokens = tokenizer.tokenize(tweet)
```

- `tokenizer.tokenize(tweet)` akan memecah teks menjadi daftar kata-kata individu (token).
- `preserve_case=False` akan membuat kata-kata menjadi huruf kecil (bagian dari case folding juga).

### d. Tuliskan/screenshotkan Filtering

Filtering adalah proses membersihkan teks dari karakter atau kata yang tidak diperlukan, seperti angka, URL, tanda baca, stopwords, dan emotikon.

**Jawab:**

→ **Bagian kode yang melakukan filtering:**

```
def tweet_clean(tweet):
    #remove angka
    tweet = re.sub('[0-9]+', '', tweet)
    # print(f"ss")
    # remove stock market tickers Like $GE
    tweet = re.sub(r'\$\w*', '', tweet)
    # remove old style retweet text "RT"
    tweet = re.sub(r'RT: [\s]+', '', tweet)
```

```

#remove hyperlinks
tweet = re.sub(r'https?:\/\/\.[^\r\n]*', '', tweet)

#remove coma
tweet = re.sub(r',', '', tweet)

# remove hashtags
# only removing the hash # sign from the word
tweet = re.sub(r'#', '', tweet)

#Happy Emoticons
emoticons_happy = set([
    ':-)', ':)', ';)', ':0)', ':]', '3', ':c)', ':>', '=]',
    ':-^)', ':-D', ':D', '8-D', '8D', '-3', '-3', ':-))', ":'-)"
    'x-D', 'xD', 'X-D', 'XD', '>:P', 'x-p', 'xp', 'XP', ':-p',
    'p', 'p', 'b', 'b', '>:)', '<3' ])

#Sad Emoticons
emoticons_sad = set([
    'L', ':-/', '>:/', 'S', '>:', '>:[', ':-(', ':[', ':-||',
    ':-[', ':-<', '=\\', '=/', '>:', ':(', '>.<', 'c', ':{',
    '>:\\', ';(' ])

#all emoticons (happy + sad)
emoticons = emoticons_happy.union(emoticons_sad)

#tokenize tweets
tokenizer = TweetTokenizer(preserve_case=True,
strip_handles=True, reduce_len=True)

tweet_tokens = tokenizer.tokenize(tweet)

# print(f"Word after tokenizer : {tweet_tokens}")

tweets_clean = []

for word in tweet_tokens:
    if (word not in stopwords_english and word not in
emoticons and word not in string.punctuation): # remove
punctuation
        # print(f"Word before stemming: {word}")
        stem_word = stemmer.stem(word) #stemming word
        # print(f"Word after stem: {stem_word}")
        tweets_clean.append(stem_word)

```

```

        return tweets_clean
df['tweet_clean'] = df['remove_user'].apply(lambda x:
tweet_clean(x))

#remove punct
def remove_punct(text):
    text = " ".join([char for char in text if char not in
string.punctuation])
    return text
df['Tweet'] = df['tweet_clean'].apply(lambda x:
remove_punct(x))

```

#### e. Tuliskan/screenshotkan Stemming

Stemming adalah proses mengubah kata menjadi bentuk dasarnya.

**Jawab:**

→ Bagian kode yang melakukan stemming menggunakan Sastrawi:

```
stem_word = stemmer.stem(word) #stemming word
```

#### f. Tuliskan/screenshotkan Simpan data text bersih

**Jawab:**

```

df.sort_values('Tweet', inplace = True)
df.drop(df.columns[[0,1]], axis = 1, inplace = True)
df.drop_duplicates(subset = 'Tweet', keep = 'first', inplace
= True)
df.to_csv('ramadan_clean_tweet.csv', encoding='utf8',
index=False)
df.head(10)

```

### 4. Lampirkan file RAW hasil Crawling dan file bersih hasil preprocessing